

Ética & Inteligência Artificial

Marcelo Antunes Soares Fantini
Rubens de Castro Pereira

RA 108341
RA 217146

30 de março de 2023

1. Defina Ética em Inteligência Artificial.

A ética em Inteligência Artificial (IA) representa um conjunto de valores e princípios que devem ser respeitados por todos os atores envolvidos no ciclo de vida de sistemas de IA com destaque ao respeito, proteção e promoção dos direitos humanos, liberdades fundamentais e dignidade humana, diversidade e inclusão [1].

2. Apresente uma notícia recente de um problema de Ética em IA.

O site de notícias *The Verge* publicou o artigo *Anyone can use this AI generator - that's the risk* [2]. A notícia discute o avanço da inteligência artificial na área de programas de texto-para-imagens. Esses programas abriram a possibilidade para que pessoas pudessem gerar imagens por meio da inteligência artificial com comandos (*prompts*) de texto, utilizando uma vasta base de imagens para gerar o pedido.

A inteligência artificial está longe de ser perfeita. Ela demonstra dificuldades para gerar mãos, pode gerar deformidades nas pessoas, entre outras falhas. A Figura 1 ilustra um comando de texto cuja imagem gerada possui deformidades. Entretanto, essas falhas não são incômodas para quem está empolgado com a tecnologia, que pode gerar qualquer imagem que alguém possa imaginar.




Figura 1: Imagem gerada por um prompt pedindo uma escultura hiperrealista de uma face humana. Encontrada no Lexica.

A empresa OpenAI possui o gerador de imagens DALL-E com uma cota finita gratuita mensal. Uma vez esgotada é necessário pagar para gerar novas imagens, criando uma pequena barreira para aqueles os interessados. O Google possui um gerador de imagens chamado Imagen mas que não está aberto ao público.

Além desses geradores, ganhou notoriedade o método Stable Diffusion difundido pela empresa Stability AI. A empresa, chefiada pelo CEO Emad Mostaque, foca no desenvolvimento open source de Stable Diffusion. Mostaque diz que a iniciativa open source é sobre “colocar o controle nas mãos das pessoas que construirão e entenderão a tecnologia.” Entretanto, isso significa colocar todas essas capacidades nas mãos do público, para o bem ou para o mal.

Um dos problemas do Stable Diffusion é que não existem restrições sobre o tipo de conteúdo que pode ser gerado. Outros geradores, como DALL-E e Imagen, possuem restrições severas nas palavras-chave e no conteúdo que podem gerar, enquanto que o Stable Diffusion pode ser utilizado localmente. Uma vez que o Stable Diffusion esteja na máquina local de um usuário, não

existe como restringir o que é gerado. Isto torna muito mais fácil a geração de conteúdo violento e sexual, incluindo imagens de pessoas reais. Com Stable Diffusion, o caso mais comum até o momento são usuários gerando pornografia.

Essa situação é território essencialmente desconhecido e não é possível prever quais serão as consequências de disponibilizar um modelo como esse para o público. É fácil imaginar os fins maliciosos para os quais essa tecnologia pode ser utilizada, mas isso não significa que essas previsões acontecerão.

Outro problema é o uso de imagens com direitos autorais utilizadas como treinamento e base para as imagens geradas pelo Stable Diffusion. Apesar da empresa Stability AI aplicar alguns filtros, ela não impede o uso de bancos de dados de direitos autorais. Como resultado, muitos vêem a habilidade de Stable Diffusion imitar o estilo e estética de artistas ainda vivos, configurando não apenas uma brecha de direito autoral mas também uma brecha ética.

O aspecto de direitos autorais adiciona uma nova dimensão às reclamações que dizem que ferramentas como Stable Diffusion estão substituindo trabalhos de artistas humanos. Está roubando trabalhos de artistas, emulando as habilidades sem remunerá-los, e, ao fazer isso, está contrabandeando as habilidades que esses indivíduos necessitaram de horas e horas para aperfeiçoar.

3. Apresente um artigo científico recente de uma solução para um problema de Ética em IA.

O artigo *A Pathway Towards Responsible AI Generated Content* tem como propósito apresentar os riscos decorrentes do uso de modelos de Geração de Conteúdo por Inteligência Artificial (GCIA), principalmente aqueles voltados para a produção de conteúdo artístico. Ele discute e apresenta possíveis ações para o uso responsável, seguro, e ético desses modelos na sociedade [3]. Os tipos de conteúdos considerados nesses modelos são bastante variados, podendo ser imagens, textos, áudios ou vídeos. A maioria dos geradores de textos tem como base GPT (*Generative Pre-trained Transformers*) e suas versões evoluídas GPT-2 e GPT-3. Existem também os geradores de imagens a partir de textos (*text-to-image*), tendo como base CLIP e OpenClip. Destacam-se recentemente o DALL-E e DALL-E 2, desenvolvidos pela OpenAI, e o Stable Diffusion, desenvolvido pela Stability AI.

O uso extensivo desses modelos traz preocupações muito relevantes. Podem afetar a privacidade e gerar preconceito, informações tóxicas, desinformações, desrespeitar propriedade intelectual e existem potenciais usos indevidos por empresas ou pessoas.

Recentemente surgiram discussões com a disponibilização de novas funcionalidades do ChatGPT, desenvolvido pelo OpenAI, permitindo depurar códigos fonte de programas de computador ou elaborar trabalhos escolares e acadêmicos. Surgem potenciais riscos com os produtos dessas funcionalidades, pois os modelos respondem conforme foram treinados, replicando conteúdos. O conjunto de dados utilizados para treinamento frequentemente sem atribuição de origem e direitos autorais e sem curadoria cuidadosa. Além disso, a maioria dos modelos de GCIA decodificadores de textos são treinados com grandes quantidades de dados obtidos da internet. Consequentemente, eles podem conter desvios e vieses (*biases*) relacionados a temas sociais, toxicidade, e outros riscos inerentes aos grandes modelos de linguagens.

Para que os modelos de GCIA sejam considerados responsáveis deve-se incluir nas considerações éticas: privacidade, vieses (tendências), toxicidade, desinformação, e proteção da propriedade intelectual. Adicionalmente, também devem contemplar robustez, possibilitar explicações dos resultados, oferecer código fonte aberto, permitir consentimento dos autores para uso nos modelos, respeitar créditos autorais dos resultados, oferecer compensação aos proprietários dos dados quando estes são utilizados nos modelos e, por fim, possibilitar um ambiente amigável para o seu uso.

Os modelos geradores de conteúdo permitem uma vulnerabilidade de ataques de privacidade devido ao grande volume de dados duplicados nos conjuntos de dados de treinamento. Esse comportamento de replicação tem sido extensivamente estudado nestes modelos e resultar em imagens como a combinação de fundo e de objetos de imagens reais. Um exemplo desse resultado ocorreu com a Stable Diffusion, em que a imagem final era a combinação simples de imagens do dataset de treinamento considerando o plano de fundo (*background*) e plano da frente (*foreground*). Devido a esse comportamento de replicação esses resultados divulgam imagens particulares de seus autores reais como se fossem imagens do próprio modelo, demonstrando a memorização dos modelos ao longo do treinamento, que acaba reproduzindo, e não criando, novas imagens.

As questões de privacidade ainda não possuem soluções definitivas, mas ações vem sendo tomadas para minimizar essas consequências danosas. As companhias tem disponibilizado um website para fornecer identificação de imagens já treinadas como a companhia de arte Spawning AI. **(Vamos tentar reescrever?) Outra ação para evitar a duplicação de dados é o uso de técnicas de duplicação removendo de forma ampla dados duplicados utilizados em treinamento. A**

empresa OpenAI segue nessa linha, reconhecendo as dificuldades para eliminar dados duplicados. Outras companhias como Microsoft e Amazon têm adotado medidas para prevenir o compartilhamento de dados sensíveis pelos seus empregados, evitando o uso desses dados em futuras versões de modelos de GCIA. Atualmente as medidas para evitar o vazamento de dados privados são insuficientes e ainda faz-se necessário explorar sistemas confiáveis para a detecção de dados duplicados em modelos generativos e uma maior investigação no processo de memorização e generalização em sistemas de aprendizado profundo.

Os dados de treinamento utilizados nos modelos de Inteligência Artificial (IA) são obtidos do mundo real, podendo reforçar estereótipos indesejados, excluir ou marginalizar grupos de indivíduos, exacerbar toxicidade no discurso e podendo levar à incitação ao ódio e violência. Um exemplo é o conjunto de dados LAION (*Large-scale Artificial Intelligence Open Network*), contendo conteúdos relacionados à estereotipagem social, pornografia, calúnias racistas e violência. O uso de filtros nos dados é uma possibilidade para minimizar esses problemas, mas podem introduzir vieses nos dados de treinamento que serão propagados pelos modelos.

Para ilustrar modelos que podem produzir resultados tendenciosos, a Figura 2 apresenta imagens geradas por meio do comando *prompt* “Three engineers running on the grassland”. O resultado foram indivíduos do sexo masculino e brancos, excluindo indivíduos de minorias raciais e indicando uma ausência de diversidade de gênero. Outras estratégias para minimizar esses vieses são o emprego de técnicas de pré-treinamento aplicadas aos dados antes do treinamento do modelo e o contínuo treinamento com as informações mais recentes. Assim, evita-se o surgimento de lacunas de informação e garante-se que os modelos permaneçam atualizados, relevantes, e benéficos para a sociedade. Existem oportunidades desafiadoras para investigação mais profunda de vieses, toxicidade e desinformação em todo o ciclo de vida de desenvolvimento dos modelos.

À medida que as técnicas avançam surgem situações de violação de direitos autorais com os conteúdos gerados artificialmente. Um dos desafios é associar a legislação da propriedade intelectual, que define de forma clara o que é um trabalho original, a quando o direito à propriedade intelectual é violado. Por isso, a definição de propriedade intelectual no âmbito dos modelos de geração de conteúdos por IA permanece obscura e indefinida. Alguns exemplos de problemas surgem em modelos geradores baseados em texto-para-imagem, acusados de infringir os trabalhos de artistas plásticos (**será que não seria apenas artistas?**), consequência do uso de grandes volumes de imagens da internet para o treinamento dos modelos como Stable Diffusion.

Uma estratégia de minimizar a violação da propriedade intelectual é permitir que os artistas que considerarem seus direitos autorais violados tenham seus trabalhos removidos dos datasets, como a empresa Midjourney. Outras companhias, como Stability AI, planejam permitir que os próprios artistas removam seus trabalhos, dando mais flexibilidade ao processo de proteção intelectual. Para textos a marca d’água têm sido utilizada auxiliando na verificação do uso de fontes sem permissão para a geração de conteúdos. A companhia OpenAI trabalha para disponibilizar um classificador que consiga diferenciar entre texto gerado por modelos de IA e textos escritos por pessoas.

Após breve análise dos principais elementos desejáveis no escopo de GCIA responsáveis, faz-se necessário avaliar outras características que devem existir nos modelos.

Os conteúdos gerados pelos modelos podem propagar informação oculta, violenta, danosa e falsa, em que os textos e imagens são difíceis de serem diferenciadas de conteúdos criados por pessoas. As-



Figura 2: Imagem gerada a partir do texto “Three engineers running on the grassland” by Stable Diffusion v2.1.1.

sim, podem ser utilizados para publicação de notícias falsas (*fake news*), boatos e até mensagens de assédio. Além disso, o uso para fins comerciais gera bastante controvérsia, passando por imagens e textos inseridos em produtos e soluções à integração dos modelos em software e sistemas. A possibilidade da substituição de determinados trabalhos realizados por pessoas de uma forma descontrolada é desconfortável para muitos.

Os modelos podem ser vistos como caixas-preta tendo uma entrada, um processamento que é oculto aos olhos dos usuários, e uma saída. Isto leva a uma necessidade de se explicar como e baseado em que o resultado é criado. Disponibilizar abertamente o código-fonte desses modelos pode resultar em riscos de se propagar as falhas já mencionadas nos novos modelos, produzindo impactos imprevisíveis. A possibilidade dos usuários fornecerem devolutivas *feedback* sobre o uso dos modelos é algo necessário para se ter modelos responsáveis. Como exemplo, a OpenAI possibilita que usuários enviem feedback que são utilizados para a correção e melhoria, reduzindo possíveis impactos negativos.

Outro impacto é o elevado consumo de energia elétrica pelos computadores para treinar os modelos cada vez maiores, podendo ter bilhões ou trilhões de parâmetros. Isso leva a uma nova reflexão ainda sem solução. Os modelos deveriam buscar o equilíbrio de benefícios onde determinados grupos de pessoas podem ser privilegiadas em detrimento de outros grupos resultando em desigualdades globais.

Por fim, observa-se nos modelos de IA a existência de conflitos entre seus diversos objetivos, pois ao focar na prevenção de determinado risco pode-se criar uma vulnerabilidade em outro tipo de risco. Um exemplo seria quando se busca mitigar o uso de termos tóxicos em modelos de linguagem podem surgir vieses na predição que discrimina outras comunidades.

O artigo finaliza indicando que GCIA ainda está em uma fase embrionária, em crescente e rápida evolução, com tecnologias impressionantes relacionadas ao campo das artes mas com vários riscos inerentes ao seu uso. Fornece um resumo dos atuais e potenciais riscos do uso de modelos possibilitando que empresas e usuários previnam-se, propondo ações para minimizar a ocorrência desses riscos. Conhecer-los, discutir-los, medi-los e agir é um bom caminho para o futuro dos modelos responsáveis.

4. Apresente e discuta sobre a análise do ChatGPT.

Prompt (questão) enviada ao ChatGPT: *"Comente, em até 500 palavras, a reportagem abaixo: Anyone can use this AI art generator — that's the risk."*

Respostas do ChatGPT

1ª consulta - Título da consulta atribuída pelo ChatGPT: *Food allergy inquiry.*

A reportagem "Anyone can use this AI art generator — that's the risk" traz à tona uma questão atual e importante: a democratização do uso de inteligência artificial para a criação de arte, e os possíveis riscos envolvidos.

O artigo destaca que, com o avanço da tecnologia, ferramentas de IA estão se tornando cada vez mais acessíveis para pessoas comuns, permitindo que qualquer um possa criar arte com apenas alguns cliques. Embora isso possa ser visto como algo positivo, especialmente para aqueles que não têm habilidades artísticas, há um risco envolvido nesse processo.

O texto menciona que a facilidade de uso dessas ferramentas pode levar a uma inundação do mercado com arte de qualidade duvidosa, o que poderia prejudicar a percepção pública sobre a arte em geral. Além disso, há o risco de que pessoas mal-intencionadas usem essas ferramentas para criar imagens enganosas ou até mesmo propagandas falsas.

O artigo também aborda a questão dos direitos autorais, uma vez que muitas dessas ferramentas usam imagens e dados fornecidos pelos usuários para criar novas obras. Isso pode levar a disputas legais, especialmente se o usuário não tiver conhecimento ou consentimento sobre o uso de suas imagens.

Em suma, a reportagem destaca que embora o uso de IA para criar arte seja uma tendência crescente e interessante, há um risco associado a essa democratização, especialmente quando se trata de questões éticas e legais. Portanto, é importante que as pessoas estejam cientes desses riscos e usem essas ferramentas de maneira responsável e informada.

2a. consulta - Título da consulta atribuída pelo ChatGPT: *Food allergy inquiry.*

A reportagem "Anyone can use this AI art generator — that's the risk" aborda a crescente popularidade das ferramentas de geração de arte baseadas em inteligência artificial e as preocupações que surgem com o uso dessas ferramentas por qualquer pessoa, incluindo aqueles sem habilidades artísticas.

A matéria começa explicando como essas ferramentas funcionam, usando como exemplo o aplicativo DeepArt.io, que utiliza redes neurais artificiais para transformar fotografias em obras de arte no estilo de grandes artistas, como Van Gogh e Picasso. Embora o resultado seja impressionante, a reportagem aponta que a criação de arte através de algoritmos não é nova e cita exemplos anteriores, como a série "Neural Art" de Leon Gatys.

No entanto, a reportagem destaca a facilidade com que essas ferramentas estão disponíveis para qualquer pessoa com acesso à internet, e a preocupação que isso pode representar para a originalidade e autenticidade da arte. A reportagem cita um exemplo recente em que uma obra gerada por IA foi vendida em leilão por US \$ 432.500, gerando debates sobre o valor real da arte produzida dessa maneira.

Outra preocupação abordada na reportagem é a possibilidade de que essas ferramentas possam ser usadas para produzir arte falsificada. Como a geração de arte por IA é baseada em algoritmos que podem ser facilmente replicados, a autenticidade de uma obra pode ser questionada, especialmente se não houver maneira de verificar a fonte original da imagem usada para gerar a obra.

A reportagem também discute as implicações éticas da geração de arte por IA. Como a criação de arte é muitas vezes vista como uma expressão pessoal e única do artista, o uso de ferramentas de geração de arte pode levantar questões sobre a autoria e originalidade da obra produzida. Além disso, a reportagem destaca a possibilidade de que essas ferramentas possam ser usadas para perpetuar preconceitos e estereótipos, como já ocorreu em casos de algoritmos de reconhecimento facial que foram criticados por reproduzirem discriminação racial.

Em resumo, a reportagem "Anyone can use this AI art generator — that's the risk" aborda uma questão complexa e multifacetada. Embora as ferramentas de geração de arte por IA ofereçam possibilidades criativas interessantes, elas também geram preocupações sobre a originalidade, autenticidade e ética da arte produzida. A reportagem destaca a importância de se refletir sobre essas questões à medida que a tecnologia continua a se desenvolver e se tornar mais acessível.

3a. consulta - Título da consulta atribuída pelo ChatGPT: *AI Art Generator Risks.*

A reportagem em questão trata de um gerador de arte alimentado por inteligência artificial (IA) que permite a qualquer pessoa criar imagens a partir de algoritmos de aprendizado de máquina. Embora isso possa parecer empolgante para muitos, a matéria alerta sobre os riscos envolvidos nesse tipo de tecnologia, que podem ir desde o uso não autorizado de imagens até a disseminação de desinformação.

O uso da IA na arte não é uma novidade. Muitos artistas têm explorado as possibilidades da tecnologia para criar obras únicas e inovadoras. O que torna o gerador de arte em questão preocupante é o fato de estar disponível para qualquer pessoa sem restrições ou limitações. Isso significa que qualquer um pode gerar imagens que parecem autênticas, mas que na verdade foram criadas por uma máquina.

Um dos principais riscos é a disseminação de imagens falsas ou enganosas. Com o gerador de arte, é possível criar imagens realistas que parecem genuínas, mas que na verdade foram criadas por um algoritmo. Isso pode ser usado para criar notícias falsas, campanhas de desinformação ou até mesmo para difamar pessoas. Além disso, há o risco de que as imagens geradas sejam usadas sem autorização, violando direitos autorais e de propriedade intelectual.

Outro problema é a falta de transparência no processo de criação da arte. O gerador de arte não permite que o usuário tenha controle sobre o que está sendo gerado, o que significa que a imagem final pode ter sido criada com dados de treinamento questionáveis ou enviesados. Isso pode levar a uma série de problemas éticos e morais, como a perpetuação de estereótipos ou discriminação racial.

Embora o gerador de arte seja uma ferramenta poderosa e interessante, é importante reconhecer

os riscos envolvidos em seu uso. É necessário que os desenvolvedores dessas tecnologias levem em consideração a ética e a responsabilidade social ao criar ferramentas que possam ser usadas por qualquer pessoa. Os usuários também devem estar cientes dos riscos envolvidos e usar a tecnologia de forma responsável e ética.

Análise das respostas do ChatGPT

Observa-se que as respostas fornecidas pelo ChatGPT utilizando o mesmo prompt (comando ou questão) em diferentes tempos não foram iguais (mesma resposta textual), mas contendo ideias similares entre elas.

As respostas abordaram que o tema é atual e importante devido à democratização do uso da Inteligência Artificial para a criação de arte e destaca os riscos inerentes ao processo de criação e entrega dos conteúdos gerados. Destaca também a facilidade de acesso de qualquer pessoa a essas ferramentas que produz arte de forma muito semelhante ao famosos artistas da humanidade. Enumera riscos como novos conteúdos de arte com qualidade duvidosa, obras, imagens e propagandas falsas, ausência de autenticidade nas obras, disseminar ideias preconceituosas, discriminação racial, desrespeito a direitos autorais, dentre outros riscos.

Por fim, as respostas indicam que o uso da IA é uma tendência atual e em crescimento, mas destaca os riscos principalmente aqueles relacionados ao uso irresponsável e às questões éticas e legais.

Referências

- [1] Scientific United Nations Educational and Cultural Organization (UNESCO). Recommendation on the ethics of artificial intelligence, 2022.
- [2] James Vincent. Anyone can use this AI art generator - that's the risk, 9 2022.
- [3] Chen Chen, Jie Fu, and Lingjuan Lyu. A Pathway Towards Responsible AI Generated Content, 2023.